

Exercício 2

Integrantes: Lucas Pimentel da Silva e Tacio Vieira Machado

a) Descrição do problema e do contexto a ser abordado no problema que originou o projeto ora em desenvolvimento

O Instituto do Patrimônio Histórico e Artístico Nacional (IPHAN) é uma autarquia federal vinculada ao Ministério da Cultura (MinC), incumbida da proteção, gestão, promoção e difusão do patrimônio cultural brasileiro. Entre suas atribuições legais, destaca-se a participação como órgão interveniente no processo de licenciamento ambiental, cabendo-lhe avaliar os impactos de empreendimentos sobre bens culturais acautelados em âmbito federal – uma competência que se insere no arcabouço da Lei nº 3.924/1961 (proteção de sítios arqueológicos) e das normativas ambientais correlatas.

Historicamente, essa intervenção foi operacionalizada de forma descentralizada: as Superintendências Estaduais do IPHAN ficaram responsáveis pela análise dos processos de licenciamento conduzidos por órgãos ambientais estaduais e municipais, enquanto os empreendimentos licenciados pelo IBAMA são avaliados pela sede, em Brasília. Essa arquitetura organizacional foi formalizada pela Instrução Normativa IPHAN nº 001/2015¹, que estabeleceu prazos, fluxos e competências para a manifestação técnica do Instituto.

Em setembro de 2017, com a publicação da Portaria IPHAN nº 361/2017², a autarquia migrou integralmente seu acervo processual do modelo físico para o Sistema Eletrônico de Informações (SEI), tornando-se uma das instituições federais a adotar não apenas o sistema como plataforma interna, mas também a disponibilizar seus autos para consulta externa por meio do SEI Pesquisa Pública³ – uma interface de transparência ativa que permite a qualquer cidadão acessar processos e documentos classificados como públicos.

Contudo, o volume de demandas decorrentes do licenciamento ambiental cresceu exponencialmente nos anos subsequentes, gerando um fluxo contínuo e crescente de processos que superou a capacidade operacional das Superintendências. O resultado foi sistêmico: o IPHAN passou a descumprir reiteradamente os prazos de manifestação estipulados pela IN nº 001/2015.

Diante desse gargalo crônico e recorrente, a Autarquia instituiu, por meio da Portaria IPHAN nº 259/2025⁴, o Programa de Gestão dos Processos de Licenciamento Ambiental (PGLic). O PGLic representou uma inflexão organizacional: ao invés da gestão descentralizada por Superintendência, centralizou o recebimento, a triagem e a distribuição das demandas na Coordenação-Geral de Licenciamento Ambiental (CGLic), unidade sediada em Brasília. Paralelamente, o Edital nº 1/2024⁵ viabilizou a contratação de servidores temporários – técnicos e analistas – com o objetivo de atender o passivo acumulado de processos pendentes de manifestação.

A operacionalização do PGLic, contudo, trouxe um novo desafio: os técnicos e analistas recém-incorporados à CGLic precisam, para cada processo, consultar manualmente a totalidade dos autos

1 Disponível em https://www.gov.br/iphan/pt-br/patrimonio-cultural/licenciamento-ambiental/Instrucao_normativa_01_2015.pdf/@@display-file/file. Acesso em: 7 de set. de 2026.

2 Disponível em <https://www.in.gov.br/web/dou/-/portaria-n-361-de-14-de-setembro-de-2017-19294773>. Acesso em: 7 de set. de 2026.

3 Disponível em <http://sei.iphan.gov.br/pesquisapublica>. Acesso em: 7 de set. de 2026.

4 Disponível em <https://www.gov.br/iphan/pt-br/centrais-de-conteudo/boletins-administrativos/2025/bae-no-1-959-27-06-2025/@@display-file/file>. Acesso em: 7 de set. de 2026.

5 Disponível em <https://www.in.gov.br/web/dou/-/edital-n-1-de-3-de-dezembro-de-2024-599671293>. Acesso em: 7 de set. de 2026.

no SEI – muitas vezes centenas de páginas e dezenas de documentos – para compreender o histórico, identificar as pendências e localizar os pontos de intervenção que demandam manifestação do IPHAN. Essa tarefa de leitura e triagem manual consome tempo considerável e revela uma limitação estrutural do SEI: o sistema não dispõe de funcionalidades internas que permitam identificar automaticamente onde se encontram as pendências, os despachos sem resposta ou as exigências não atendidas dentro de um processo.

Essa deficiência se agrava pelo fato de que os processos de licenciamento ambiental no IPHAN possuem estrutura complexa e heterogênea: contêm pareceres técnicos, ofícios de órgãos ambientais, comunicações com empreendedores, projetos e relatórios de bens acautelados, mapas, fotografias, despachos internos e decisões administrativas, muitas vezes acumulados ao longo de anos. Sem ferramentas de análise automatizada, cada técnico e analista precisam reconstruir mentalmente o fluxo processual a partir de uma leitura linear dos autos – um trabalho repetitivo, suscetível a erros e ineficiente.

O problema central que este projeto se propõe a enfrentar é, portanto, o seguinte:

como automatizar a identificação de pendências e o mapeamento de fluxos processuais em processos de licenciamento ambiental tramitados no SEI/IPHAN, de modo a reduzir o tempo de triagem e acelerar a manifestação técnica da CGLic?

A hipótese que orienta esta investigação é a de que técnicas de mineração de texto (*text mining*) aplicadas sobre os autos disponíveis na Pesquisa Pública do SEI – combinadas com modelagem de grafos para representar os fluxos de tramitação – podem gerar representações automáticas dos processos que localizem pendências, identifiquem atores envolvidos e visualizem o caminho percorrido pelo processo, dispensando a leitura manual integral dos autos.

b) Revisão da literatura e trabalhos correlatos

O problema central deste projeto – a dificuldade de identificar pendências e gargalos em autos processuais eletrônicos sem depender de leitura manual exaustiva – se situa na interseção de quatro frentes de evidência: o diagnóstico institucional produzido pela própria autarquia, a produção acadêmica nacional sobre o SEI, a atuação do controle externo na implantação do processo eletrônico federal e a literatura sobre mineração de processos. Examinar essas quatro frentes permite distinguir com precisão o que já está consolidado daquilo que ainda precisa ser desenvolvido.

O ponto de partida é o diagnóstico institucional. O Relatório Institucional da Ouvidoria-Geral do IPHAN referente ao exercício de 2024 documenta de forma quantificada o problema operacional que motiva este projeto. O documento revela que a reclamação foi o tipo predominante de manifestação recebida no período e que o subassunto mais recorrente foi o atraso na análise de processos de licenciamento ambiental, com concentração expressiva na Superintendência do IPHAN em São Paulo. Mais revelador ainda: o tempo médio de resposta da autarquia na plataforma Fala.BR situou-se significativamente acima da média dos órgãos do Poder Executivo federal, acompanhado de um índice de satisfação correspondentemente baixo. Diante desse quadro, a resposta institucional foi a construção de uma Base de Conhecimento com respostas padronizadas, a revisão da árvore de classificação das manifestações, a edição de orientações específicas sobre demandas de licenciamento e a produção de relatórios técnicos gerenciais. Trata-se, portanto, de um conjunto de medidas voltadas à padronização do atendimento ao cidadão e à simplificação do fluxo de ouvidoria – não à instrumentação analítica dos autos processuais em si. O problema está, assim,

institucionalmente reconhecido e documentado; o que falta é um instrumento que permita identificar, dentro de cada processo, o ponto exato onde a tramitação se interrompe.

O segundo corpo de evidência é a literatura acadêmica nacional. A revisão integrativa conduzida por Sousa *et al.* (2026), que mapeou a produção sobre o SEI nas duas principais bases científicas brasileiras – a Biblioteca Digital Brasileira de Teses e Dissertações e o Portal de Periódicos da CAPES –, localizou quarenta e quatro trabalhos e selecionou dezesseis para análise aprofundada, distribuídos em cerca de dez temáticas. Os temas dominantes são a adoção e avaliação do sistema e a inovação e adaptação institucional. A conclusão é de consenso: o SEI é reconhecido como uma contribuição significativa à transparência pública, à gestão documental e à eficiência administrativa. Contudo, ao examinar as temáticas cobertas, observa-se uma ausência notável: nenhum dos estudos mapeados aborda a extração automatizada de informação a partir do conteúdo dos autos processuais. Essa lacuna não é acidental. Ela revela que a pesquisa acadêmica brasileira sobre o SEI tem se concentrado em avaliá-lo como política pública de gestão – medindo seus efeitos na transparência, na economia de recursos e na racionalização de fluxos –, mas não em explorá-lo como fonte de dados passível de estruturação computacional. Em outras palavras, o SEI tem sido objeto de avaliação institucional, não de exploração analítica.

O terceiro corpo provém do controle externo. O Acórdão nº 484/2021 do Plenário do TCU, fruto da auditoria TC 027.948/2019-6, avaliou a implementação do processo administrativo eletrônico em mais de uma centena de Instituições Federais de Ensino vinculadas ao Ministério da Educação, abrangendo o SEI e outras plataformas. Entre os achados, o Tribunal registrou o descumprimento generalizado do prazo fixado pelo Decreto nº 8.539/2015, o ritmo lento de migração do acervo físico para o digital, a inexistência ou restrição da funcionalidade de consulta pública em diversas entidades e a insuficiência dos normativos internos de regulamentação. Dois desdobramentos dessa deliberação são particularmente relevantes para este projeto. No plano normativo, o TCU determinou que as instituições assegurem a consulta pública do inteiro teor de documentos e processos independentemente de cadastro, autorização ou senha, estabelecendo que, como regra, documentos e processos sejam classificados como públicos, sendo o sigilo a exceção. Esse entendimento do órgão de controle externo respalda metodologicamente a opção deste projeto por utilizar o SEI Pesquisa Pública como via de acesso aos dados, conferindo-lhe legitimidade à luz da Lei de Acesso à Informação. No plano prático, porém, o Tribunal também constatou uma advertência importante: mesmo quando um documento é classificado como público, parcela relevante das instituições não exhibe seu conteúdo integral na consulta, porque a exposição depende de parametrização específica do sistema e da classificação atribuída no momento da criação de cada peça. A disponibilidade do conteúdo, portanto, não é garantida por padrão – é uma condição que precisa ser verificada caso a caso antes de qualquer inferência. Registre-se, por fim, que o escopo da auditoria limitou-se às instituições de ensino vinculadas ao MEC, de modo que a extensão desses achados ao IPHAN constitui uma analogia argumentada, não uma demonstração direta, embora a natureza sistêmica dos problemas identificados torne essa analogia plausível.

O quarto conjunto reúne trabalhos sobre a estruturação automatizada de dados processuais. Salvadori (2024) propôs e implementou um sistema para análise e publicação de dados de processos eletrônicos em organizações públicas, operando sobre acervos do SEI de instituições federais de ensino. A arquitetura combina raspagem das páginas HTML da consulta pública – única via disponível, já que o sistema não oferece interface programática de interoperabilidade –, uma ontologia de domínio inspirada em vocabulário de dados abertos governamentais, a conversão dos dados tabulares para RDF e o emprego de um modelo de linguagem acessado remotamente para

enriquecer os registros. Três constatações do autor são diretamente pertinentes. Primeiro, o campo destinado ao assunto do documento é preenchido em texto livre, sem taxonomia controlada, gerando dezenas de milhares de valores distintos em uma única instituição, o que inviabiliza a recuperação da informação por esse parâmetro. Segundo, a maioria dos documentos não possui autoria identificável, seja por ausência de assinatura digital, seja por se tratarem de arquivos não textuais. Terceiro, a raspagem alcançou apenas documentos nato-digitais em HTML, deixando de fora anexos que demandariam reconhecimento óptico. É igualmente relevante delimitar o que esse trabalho não faz. O sistema produz três saídas principais: a reclassificação do assunto a partir do conteúdo, a identificação do autor e de seu papel, e a identificação das pessoas mencionadas no texto. Não há extração de eventos processuais, de sequência temporal ou de qualquer estrutura de fluxo, e a ontologia proposta não contempla classes de evento ou de atividade. O objetivo declarado é a estruturação e publicação dos dados como dados conectados, e não a reconstrução do comportamento do processo. Existe, portanto, precedente técnico consolidado para a extração e estruturação de informação a partir de acervos do SEI, mas não para a reconstrução da dimensão processual desses acervos.

O arcabouço teórico que sustenta essa reconstrução é o da mineração de processos, cuja formulação de referência é a de van der Aalst (2016). O campo se organiza em torno de três modalidades – descoberta de modelos a partir de registros de execução, verificação de conformidade entre o comportamento observado e um modelo prescrito, e aprimoramento de modelos existentes com dados reais – e tem como insumo essencial o log de eventos, estrutura que requer minimamente um identificador de caso, uma atividade e um carimbo de tempo, admitindo ainda o recurso responsável e atributos adicionais. A partir desse log, algoritmos de descoberta com propriedades distintas induzem modelos formais cuja qualidade é avaliada em quatro dimensões em tensão mútua: aderência ao comportamento registrado, precisão (capacidade de não permitir comportamento não observado), generalização e simplicidade estrutural. Sobre o modelo descoberto podem ser projetadas perspectivas complementares, entre as quais a temporal, que localiza gargalos ao calcular esperas por transição, e a organizacional, que reconstrói redes de transferência de trabalho entre unidades e servidores.

A convergência desses quatro conjuntos permite enunciar a lacuna com clareza. O atraso na análise dos processos de licenciamento está institucionalmente documentado e quantificado, mas as respostas até aqui se dirigiram ao atendimento ao cidadão, e não ao diagnóstico dos autos. A produção acadêmica nacional sobre o SEI examina o sistema como política de gestão e não o toma como fonte de dados estruturáveis. O controle externo, ao mesmo tempo em que respalda normativamente o uso da consulta pública como via de acesso, adverte que a disponibilidade do conteúdo é condicionada e precisa ser medida. E, embora exista precedente técnico para estruturar dados de processos eletrônicos, não há solução para reconstruir a sequência de eventos que constitui o fluxo de trabalho – justamente o insumo de que a mineração de processos depende. É nessa interseção que o presente projeto se situa, propondo-se a verificar, em caráter experimental e sobre um conjunto reduzido de casos integralmente conferidos à mão, se é possível reconstruir automaticamente o fluxo processual a partir dos autos disponíveis na consulta pública.

c) Delineamento da metodologia proposta para resolvê-lo

A metodologia proposta configura uma pesquisa aplicada de natureza exploratória, estruturada como experimento de prova de conceito. Seu objetivo é desenvolver e testar um método capaz de reconstruir, a partir dos autos disponíveis no SEI Pesquisa Pública, os fluxos de trabalho dos processos de licenciamento ambiental do IPHAN sob a forma de grafos processuais, de modo a revelar pendências, gargalos e padrões de tramitação que hoje exigem leitura manual. O experimento incidirá sobre cinco processos mapeados integralmente à mão, que constituirão o

gabarito para comparação. A pergunta central é de viabilidade técnica – se o método reproduz o que um analista extrairia dos mesmos autos – e não de generalização estatística, que demandaria amostra muito maior e será objeto de etapa posterior.

O trabalho segue o ciclo CRISP-DM, adaptado para dados textuais e para o paradigma da mineração de processos. Essa adaptação é necessária porque, em mineração de texto, o espaço de atributos é construído durante o pré-processamento (tokenização, normalização, ponderação), e porque o produto final não é um modelo preditivo, mas um modelo de processo submetido a verificação de conformidade, o que exige métricas próprias do *process mining*. A implementação será feita em R, com levantamento sistemático das bibliotecas necessárias em cada etapa – aquisição de documentos, estatística descritiva, processamento de linguagem natural, descoberta de processo e verificação de conformidade.

O desenho separa três camadas de dados com níveis distintos de complexidade. A camada estrutural, extraída por leitura determinística das tabelas de andamentos e documentos, fornece a sequência de atos, unidades responsáveis e datas. A camada de assinatura, extraída dos blocos de assinatura eletrônica, fornece carimbo de tempo com hora, nome e cargo do signatário, além do estado de completude de cada ato. A camada semântica depende de mineração de texto para identificar o desfecho de cada ato – deferimento, solicitação de complementação ou indeferimento – e opera apenas sobre atos cuja existência, data e autoria já são conhecidas pelas camadas anteriores.

A seleção dos processos será por amostragem aleatória simples, sem estratificação, a partir dos processos de licenciamento autuados em 2026 e registrados no Banco de Autorizações de Pesquisas Arqueológicas do IPHAN. O sorteio usará semente registrada para garantir reprodutibilidade. Embora cinco casos não confirmem representatividade estatística, e a aleatorização elimina o viés de seleção do pesquisador. Processos inelegíveis por indisponibilidade ou restrição de acesso serão substituídos mediante novo sorteio, com registro da exclusão e seu motivo.

A escolha do exercício de 2026 é estratégica: os autos desse período contêm poucos documentos, o que viabiliza o mapeamento manual completo e a comparação registro a registro. Além disso, todos tramitam sob a Instrução Normativa IPHAN nº 06/2025⁶, que revogou a IN nº 01/2015, assegurando regime normativo único e dispensando o tratamento de mudanças estruturais de fluxo.

O gabarito será construído antes de qualquer execução automática, para evitar contaminação. Para cada processo serão registrados manualmente: a relação completa de documentos com tipo, data e unidade; a sequência de andamentos; os signatários e datas de assinatura; a classe de evento regulatório de cada peça e ato; o desfecho de cada análise; e os prazos aplicáveis com datas de início e encerramento. Embora sejam cinco casos – sobre os quais não se fará inferência populacional –, cada um contém dezenas de documentos e andamentos, de modo que a verificação das camadas estrutural e de assinatura operará sobre centenas de registros, e a da camada semântica sobre o subconjunto de atos administrativos.

Os autos serão coletados no SEI Pesquisa Pública, e não no SEI interno, por três razões: disponibilidade consistente (ao contrário das caixas internas, sujeitas a restrições de unidade gestora), independência de credenciais institucionais (garantindo reprodutibilidade) e alinhamento com a diretriz de transparência ativa documentada no Relatório Institucional da Ouvidoria-Geral (IPHAN, 2025). Documentos com dados sensíveis ou informações classificadas nos termos da LAI e da LGPD não estarão disponíveis, o que constitui limitação inerente à fonte e, simultaneamente, salvaguarda ética. A proporção de documentos efetivamente legíveis será medida e reportada caso a caso. A coleta inclui não apenas a página do processo (cabeçalho, lista de documentos e histórico de

6 Disponível em <https://www.in.gov.br/web/dou/-/instrucao-normativa-iphan-n-6-de-28-de-novembro-de-2025-672013509>. Acesso em: 11 de set. de 2026.

andamentos), mas também a abertura individual de cada documento para capturar assinaturas e desfechos.

O processamento se organiza em cinco estágios encadeados, cada um gravando seu resultado em disco antes de alimentar o seguinte. O primeiro estágio, de aquisição, localiza os autos dos processos sorteados, baixa a página do processo e de cada documento, extraindo todo o conteúdo. É o único estágio dependente de rede e intervenção humana e não se repete a cada iteração.

O segundo estágio, de leitura determinística, percorre o acervo e produzirá três tabelas – relação de documentos, histórico de andamentos e conjunto de assinaturas – a partir das quais se constrói o log de eventos, com identificador de caso, classe de ato, data da última assinatura como carimbo de tempo, unidade e servidor como recurso, e estado de completude como estágio do ciclo de vida.

O terceiro estágio, de enriquecimento semântico, identifica o desfecho de cada ato por meio de mineração de texto, já que essa informação não consta em nenhum metadado. As regras que ligam padrões linguísticos aos desfechos serão derivadas do texto da IN nº 06/2025 e do vocabulário administrativo corrente – fontes externas aos cinco casos, que assim permanecem como conjunto de verificação, e não de ajuste.

O quarto estágio, de descoberta e conformidade, distingue dois tipos de grafo com relógios distintos. O grafo organizacional, derivado do histórico de andamentos, representa unidades como nós e transferências como arestas, mostrando onde o tempo é consumido dentro do IPHAN. O grafo regulatório, derivado da lista de documentos, representa instrumentos normativos como nós e sucessão de atos como arestas, medindo o cumprimento dos prazos legais. Adota-se o grafo regulatório como espinha dorsal e o organizacional como camada explicativa, porque os prazos da IN nº 06/2025 incidem sobre a análise de peças e a emissão de manifestações, ou seja, sobre documentos, não sobre eventos de tramitação. A norma é traduzida em duas representações: a rede que descreve o fluxo prescrito e o conjunto de regras verificáveis (contagem de dias consecutivos, limite de uma solicitação de complementação por instrumento, prazos de cada classe de peça). Cada peça que inicia contagem é emparelhada ao ato que a encerra, registrando-se início, fim, dias corridos, limite, excesso e eventual prorrogação, mantendo-se separados o relógio do interessado e o da administração. O fim do prazo é tomado na data da última assinatura, pois o ato administrativo se aperfeiçoa com ela.

O quinto estágio, de avaliação, confronta o resultado automático com o gabarito registro a registro e produz o relatório final com métricas de desempenho e grafos. A validação reportará separadamente a cobertura estrutural (proporção de documentos, andamentos e assinaturas corretamente extraídos) e a cobertura semântica (proporção de desfechos corretamente identificados), além de precisão, revocação e medida harmônica por classe de desfecho, acerto na classificação dos eventos regulatórios, acerto nas datas de prazos e tempo de processamento por processo. A verificação de conformidade entre o grafo descoberto e o fluxo prescrito integra os resultados do método – os desvios encontrados representam o descompasso entre norma e prática que constitui o objeto do projeto – e será aferida pelo mesmo confronto com o gabarito.

Os critérios de sucesso são diferenciados por camada. Para as camadas estrutural e de assinatura, de natureza determinística, exige-se correspondência integral com o gabarito nos cinco casos, tratando qualquer divergência como defeito a corrigir. Para a camada semântica, serão fixados limiares mínimos de cobertura e precisão por classe, reconhecendo-se que classes pouco frequentes poderão não ser avaliáveis – circunstância a ser declarada, não contornada. O critério global é a reprodução, pelo método, do mapa processual construído manualmente, incluindo a localização das pendências e as datas de início e encerramento de cada prazo.

Quanto a presença de especialista no processo, o modelo passará por validação empírica de pelo menos um técnico e analista da CGLic, que avaliarão se os gargalos e pendências identificados correspondem à sua experiência operacional.

Referências

Instituto do Patrimônio Histórico e Artístico Nacional (IPHAN). (2025). Relatório Institucional da Ouvidoria-Geral – 2024. Disponível em https://www.gov.br/iphan/pt-br/acesso-a-informacao/participacao-social/ouvidoria/relatorios/relatorio_institucional_ouvidoria_iphan_2024_02_1_1_1.pdf/@@display-file/file. Acesso em: 7 de set. de 2026.

SALVADORI, Ivan Luiz. Análise e Publicação de Dados de Processos Eletrônicos em Organizações Públicas. In: SIMPÓSIO BRASILEIRO DE BANCO DE DADOS (SBBBD), 39., 2024, Florianópolis/SC. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2024. p. 91-103. ISSN 2763-8979. DOI: <https://doi.org/10.5753/sbbd.2024.240561>.

SOUSA, Antonio Ismael Lopes de; SANTIAGO, Lucas Arruda; ROCHA, Maria da Consolação Coelho; CAMPOS, Rafael Ramos. SEI: uma revisão integrativa sobre o Sistema Eletrônico de Informações do Governo Federal. Cadernos Cajuína, [S. l.], v. 11, n. 1, p. e1637, 2026. DOI: 10.52641/cadcajv11i1.1637. Disponível em: <https://v3.cadernoscajuina.pro.br/index.php/revista/article/view/1637>. Acesso em: 7 set. 2026.

Tribunal de Contas da União. Acórdão n. 484/2021 – TCU – plenário. relatório de auditoria. processo TC 027.948/2019-6. Acórdão, TCU, Brasília, 2021. Relator: Ministro Walton Alencar Rodrigues. Sessão de 10 mar. 2021. Ata n. 7/2021 – Plenário. Unidade Técnica: SecexEduc. Código AC-0484-07/21-P Disponível em <https://nuvem.utfpr.edu.br/index.php/s/RpbfA5ouf2ubmPz>. Acesso em 07 de set. de 2026.

van der Aalst, W. (2016). Process Mining: Data Science in Action. Springer, Berlin, Heidelberg, 2 edition, 2016. ISBN 978-3-662-49850-7. doi: 10.1007/978-3-662-49851-4.